

Notas informales del curso
“Procesos estocásticos en tiempo discreto”

dictado por Michael Anton Hoegele

Universidad de los Andes,
Bogotá, Colombia
en el semestre 202310

January 30, 2024

Contents

1	Procesos estocásticos	4
1.1	Repaso: Probabilidad (Honores)	5
1.2	Procesos estocásticos en tiempo discreto	6
2	Ordenando muestras	9
2.1	La estadística del orden finito	9
2.1.1	La distribución beta	9
2.1.2	La extensión para distribuciones absolutamente continuas	14
2.2	Un teorema límite para los valores extremales (Fisher-Tippett-Gnedenko)	15
2.2.1	Preliminares	15
2.2.2	Criterios para convergencia renormalizada	16
2.2.3	Los ejemplos prototípicos y la formulación del teorema principal	24
2.2.4	Técnica esencial: convergencia de los tipos distribucionales	31
2.2.5	Distribuciones max-estables y la demostración del teorema	38
2.3	Domínios de atracción	47
2.3.1	Maximal domain of attraction of Fréchet Φ_α , Type 2	48
2.3.2	Maximal domain of attraction of Weibull, Type 3	53
2.3.3	Maximal domain of attraction of Gumbel, Type 1	56
3	Cadenas de Markov en tiempo y espacio discreto	66
3.1	Ejemplo 1: A gambling problem	66
3.1.1	Probabilidades de ruina	67
3.1.2	Duración media del juego	76
3.2	Ejemplo 2: Simple (unrestricted) random walks	81
3.2.1	Esperanza y varianza	82
3.2.2	La distribución marginal	83
3.2.3	First return time distribution	85
3.2.4	Expected return times	90
3.3	Cadenas de Markov en tiempo y espacio discreto	91
3.3.1	Propiedades y ejemplos elementales	91
3.3.2	La equivalencia con sistemas dinámicos aleatorios y ejemplos más avanzados	96
3.4	El análisis de un paso	115
3.4.1	Probabilidades de llegada a un estado	115
3.4.2	Duración media hasta la llegada a un estado y tiempos de absorción	118
3.4.3	Tiempos del primer retorno (o llegada)	122
3.5	El número de retornos	126
3.5.1	Número medio de retornos	127
3.5.2	Transiencia y los diferentes tipos de recurrencia	128
3.5.3	Clasificación de estados	132
3.5.4	Recurrencia y transiencia de caminatas aleatorias simétrica sobre \mathbb{Z}^d	137
3.6	Teoremas ergódicos para $ \mathbb{S} < \infty$	140
3.6.1	Resultados preliminares	140

3.6.2	Reversibilidad	145
3.6.3	El teorema ergódico casi seguro	146
3.6.4	Irreducibilidad fuerte implica el teorema ergódico para cadenas finitas	153
3.7	Teoremas ergódicas para \mathbb{S} infinito	165
3.8	Algoritmos de simulación	169
3.8.1	El algoritmo de Metropolis-Hastings	170
3.8.2	La simulación de leyes de Gibbs (la motivación original de Metropolis-Hastings)	175
3.8.3	Simulated annealing (recocido simulado)	178
4	El proceso de Poisson simple y compuesto	184
4.1	El proceso de Poisson simple	184
4.2	El proceso de Poisson compuesto	192
5	Cadenas de Markov en tiempo continuo	198
5.1	Preliminares	198
5.2	Efectos nuevos: Explosión y congelación	203
5.3	Más sobre el proceso de Poisson	208
5.4	Jump chains	215
5.5	Teoremas ergódicas para cadenas de Markov en tiempo continuo	220
6	El movimiento Browniano	237
6.1	Desarrollo historico del movimiento Browniano	237
6.2	Construcción de Ciesielski del movimiento Browniano	238
6.3	Propiedades elementales	239

1 Procesos estocásticos

ToDo:

- Einarbeiten: Caminata aleatória sobre grafos ponderados.
- Einarbeiten: Unas de Polya.

Literatura:

1. Embrechts, Klüppelberg, Mikosch: Modelling extremal events for Insurance and Finance (1997) Springer-Verlag Berlin.
2. Prévât: Understanding Markov Chains (2018), Springer-Verlag New York.
3. El Karoui, Benaïm: Promenades aléatoires (2003), Editions de l'Ecole Polytechnique.
4. Norris: Markov Chains (1997), Cambridge University Press.

1.1 Repaso: Probabilidad (Honores)

- Espacio de probabilidad
- Variables y vectores aleatorias y sus leyes
- Leyes condicionadas e independencia
- La convolución
- Integración abstracta, momentos
- Desigualdades de momentos por momentos: Minkowski, Young, Hölder, Jensen
- Desigualdades de probabilidades por momentos: Markov, Chebyshev, Hoeffding
- distribuciones discretas
 1. Bernoulli + Binomial,
 2. uniforme discreto,
 3. multinomial,
 4. hipergeométrica,
 5. hipergeométrica multivariada,
 6. geométrica + binomial negativa
 7. Poisson,
- distribuciones absolutamente continuas
 1. uniforme
 2. beta
 3. exponencial + Gamma
 4. Cauchy
 5. normal
 6. normal multivariada
 7. chi cuadrada
- Convergencias de sucesiones de variables aleatorias
 1. \mathbb{P} -c.s.
 2. en probabilidad
 3. en L^p
 4. en distribución
- La ley de los grandes números (débil, fuerte, Glivenko-Cantelli, M-estimator)
- El teorema límite central (Caso discreto, de-Moivre-Laplace, General, Lindeberg).

1.2 Procesos estocásticos en tiempo discreto

Definition 1.1. *Un proceso estocástico en tiempo discreto con valores en \mathbb{R}^d , $d \in \mathbb{N}$ fijo, es una familia contable de variables aleatorias sobre el mismo espacio de probabilidad $(X_n)_{n \in \mathbb{N}}$,*

$$X_n : \Omega \rightarrow \mathbb{R}^d, \quad \text{medible.}$$

Remark 1.1. • Existen varias perspectivas sobre procesos estocásticos:

1. El índice $n \in \mathbb{N}$ se interpreta como “**tiempo**” y para cada $\omega \in \Omega$ el mapa $n \mapsto X_n(\omega) \in \mathbb{R}^d$ se llama **trayectoria**.
2. Por lo anterior, para cada $\omega \in \Omega$, $(X_n(\omega))_{n \in \mathbb{N}}$ es una sucesión de vectores en \mathbb{R}^d , es decir, un proceso $(X_n)_{n \in \mathbb{N}}$ puede entenderse como **un solo vector aleatorio**

$$\Omega \ni \omega \mapsto (X_n(\omega))_{n \in \mathbb{N}} \in (\mathbb{R}^d)^{\mathbb{N}}$$

con valores en las sucesiones de \mathbb{R}^d .

Ejemplo 1.2. 1. Sucesión i.i.d. $(X_n)_{n \in \mathbb{N}}$, es decir, la familia $(X_n)_{n \in \mathbb{N}}$ es una familia independiente de variables aleatorias y $X_n \stackrel{d}{=} X_1$. Entonces $(X_n)_{n \in \mathbb{N}}$ es un proceso estocástico. Es decir, en el espacio de distribuciones $\mathbb{P}_{X_n} = \mathbb{P}_{X_1}$ es solo un punto. En estadística se llama una **muestra (independiente)**.

2. Sea $(X_n)_{n \in \mathbb{N}}$ i.i.d. y

$$S_n := \sum_{i=1}^n X_i$$

entonces $(S_n)_{n \in \mathbb{N}}$ es un proceso estocástico.

Si $X_i \sim \frac{1}{2}\delta_{-1} + \frac{1}{2}\delta_1$ se llama **caminata aleatoria simétrica**, y que satisface

$$S_{n+1} = S_n + X_{n+1}, \quad S_0 = 0.$$

En caso de tener $X_i \sim (1-p)\delta_{-1} + p\delta_1$, $p \neq \frac{1}{2}$ se llama **caminata aleatoria asimétrica** y satisface la misma ecuación (verificar!).

3. Del curso Probabilidad (Honores) sabemos ya varias cosas sobre el **proceso del promedio empírico** de la muestra $(X_n)_{n \in \mathbb{N}}$ dado por

$$\bar{S}_n := \frac{1}{n} \sum_{i=1}^n X_i$$

¿Cuáles resultados sabemos sobre $(\bar{S}_n)_{n \in \mathbb{N}}$?

- (a) Si $\mathbb{E}[|X_1|] < \infty$ entonces tenemos la ley débil de los grandes números

$$\bar{S}_n \xrightarrow{P} \mathbb{E}[X_1],$$

es decir, para cada $\varepsilon > 0$ tenemos que

$$\lim_{n \rightarrow \infty} \mathbb{P}(|\bar{S}_n - \mathbb{E}[X_1]| > \varepsilon) = 0.$$

Obviamente es muy fuertes esta hipótesis de la independencia, y el resultado se puede inferir bajo hipótesis mucho más débiles (¿cuáles?).

(b) Si $\mathbb{E}[|X_1|] < \infty$ entonces tenemos la ley fuerte de los grandes números

$$\bar{S}_n \longrightarrow \mathbb{E}[X_1] \quad c.s.,$$

es decir, existe un evento $\tilde{\Omega} \in \mathcal{A}$ con $\mathbb{P}(\tilde{\Omega}) = 1$, tal que para cada $\omega \in \tilde{\Omega}$ obtenemos

$$\lim_{n \rightarrow \infty} \bar{S}_n(\omega) = \mathbb{E}[X_1].$$

En otras palabras la probabilidad del evento de los ω donde este límite no ocurre tiene peso 0. Notemos que este límite es particularmente fácil por que el objeto límite es una constante, es decir, con probabilidad 1 NO depende de ω .

¿Cuál es el resumen de las leyes de los grandes números?

$$\bar{S}_n \stackrel{\mathbb{P}/c.s.}{\approx_n} \mathbb{E}[X_1] + o\left(\frac{1}{n}\right)_{n \rightarrow \infty}$$

el promedio empírico converge al valor esperado suyaiente (desconocido), es decir, se estabiliza. Otra manera de escribir los sería

$$S_n \stackrel{\mathbb{P}/c.s.}{\approx_n} n \cdot \mathbb{E}[X_1] + o(n)_{n \rightarrow \infty}.$$

Es decir, caminatas aleatórias crecen astintóticamente de manera lineal.

(c) El próximo paso era indentifiar el error en la ley débil de los grandes números

$$b_n^\varepsilon := \mathbb{P}(|\bar{S}_n - \mathbb{E}[X_1]| > \varepsilon), \quad b_n \rightarrow 0, \varepsilon > 0.$$

Es decir identificar la sucesión $(\varepsilon_n)_{n \in \mathbb{N}}$, $\varepsilon_n \rightarrow 0$, $n \in \mathbb{N}$, tal que la sucesión

$$b_n := b_n^{\varepsilon_n} := \mathbb{P}(|\bar{S}_n - \mathbb{E}[X_1]| > \varepsilon_n) = \mathbb{P}\left(\left|\frac{1}{\varepsilon_n}(\bar{S}_n - \mathbb{E}[X_1])\right| > 1\right)$$

converga a un valor no trivial, es decir, ni 0 ($\varepsilon_n \rightarrow 0$, $n \rightarrow \infty$, converge demasiado lento a 0) ni 1 ($\varepsilon_n \rightarrow 0$, $n \rightarrow \infty$, converge demasiado rápido a 0).

¿Cómo derivar b_n ?

Sabemos que la convergenica en distribución está implicada por la convergencia en probabilidad y la última por la convergencia en L^2 (uno de los sentidos más fuertes). Por lo tanto la no convergenia de los seguntos momentos y la varianza excluye la convergencia en distribución. Por tanto, asumimos que la la varianza

$$1 = \mathbb{V}\left(\frac{1}{\varepsilon_n}(\bar{S}_n - \mathbb{E}[X_1])\right) = \frac{1}{n^2 \varepsilon_n^2} n \mathbb{V}(X_1) = \frac{1}{n \varepsilon_n^2} \sigma^2.$$

Despejando a ε_n obtenemos

$$\varepsilon_n = \frac{\sigma}{\sqrt{n}}.$$

En otras palabras, esta condicion es necesaria para que la variable aleatória

$$\frac{\sqrt{n}}{\sigma}(\bar{S}_n - \mathbb{E}[X_1])$$

converga en algún sentido implicado por la convergencia en L^2 , es decir, virtualmente todo.

¿Cuál es el resumen del teorema límite central?

$$\bar{S}_n \stackrel{d}{\approx}_n \mathbb{E}[X_1] + \frac{\sigma}{\sqrt{n}}N + o\left(\frac{1}{\sqrt{n}}\right), \quad N \sim N(0, 1)$$

el promedio muestral converge al valor esperado subyacente y podemos determinar la tasa del error por como $\frac{1}{\sqrt{n}}$, aunque el prefactor N es aleatorio.

Caminatas aleatorias asimétricas están asintóticamente dominadas por la tasa de del valor esperado,

$$S_n \stackrel{d}{\approx}_n n \cdot \mathbb{E}[X_1] + \sigma\sqrt{n}N + o\left(\frac{1}{\sqrt{n}}\right), \quad N \sim N(0, 1).$$

En el caso de aleatorias simétricas tenemos la convergencia del orden $\sqrt{n}\sigma$. Existen teoremas muy fuertes sobre estos (la ley del logaritmo iterado).

2 Ordenando muestras

2.1 La estadística del orden finito

2.1.1 La distribución beta

Definition 2.1. La distribución $BETA(\alpha, \beta)$, $\alpha, \beta > -1$ es una distribución absolutamente continua con

$$f(x) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} x^{\alpha-1}(1-x)^{\beta-1} \mathbf{1}_{[0,1]}(x)$$

Definition 2.2. Sea (X_1, \dots, X_n) , $n \in \mathbb{N}$, una familia i.i.d. con $X_i \sim U_{[0,1]}$. Sea $X_{i:n}$ el i -ésimo valor más pequeño entonces $(X_{1:n}, \dots, X_{n:n})$ se llama el **estadístico del orden**.

Remark 2.1. En este caso podemos excluir el caso de dobles porque los X_i son independientes y absolutamente continuas es decir

$$f_{(X_1, \dots, X_n)}(t_1, \dots, t_n) = \mathbf{1}_{[0,1]^n}(t_1, \dots, t_n)$$

y la medida de Lebesgue sobre $[0, 1]^n$ tiene medida cero para cualquier intersección con un subespacio de codimensión ≥ 1 . Se puede ver fácilmente

$$\mathbb{P}\left(\bigcup_{i \neq j} \{X_i = X_j\}\right) \leq n^2 \cdot \mathbb{P}(X_1 = X_2)$$

pero $\mathbb{P}(X_1 = X_2) = \int_{[0,1]^n \cap \{t_1=t_2\}} dt_1, dt_2, \dots, dt_n = 0$.

Lemma 2.2. Sea $(X_m)_{m \in \mathbb{N}}$ una sucesión i.i.d. con $X_m \sim U(0, 1)$, entonces para cada $n \in \mathbb{N}$ y $0 \leq i \leq n$ tenemos que

$$X_{i:n} \sim BETA(i, n - i + 1).$$

Proof. 1. Primero vemos que

$$\begin{aligned} \int_0^t dt_1 &= t, \\ \int_0^t \int_0^{t_1} dt_2 dt_1 &= \int_0^t t_1 dt_1 = \frac{t^2}{2} \\ \int_0^t \int_0^{t_1} \int_0^{t_2} dt_3 dt_2 dt_1 &= \int_0^t \frac{t_1^2}{2} dt_1 = \frac{t^3}{6} = \frac{t^3}{3!} \end{aligned}$$

y por inducción:

$$\int_{0 < t_n < t_{n-1} < \dots < t_1} dt_n \dots dt_1 = \int_0^t \int_0^{t_1} \int_0^{t_2} \dots \int_0^{t_{n-1}} dt_n \dots dt_1 = \frac{t^n}{n!}.$$

Por tanto para $a_1 \leq b_1 < a_2 \leq b_2 < a_3 \leq b_4 < \dots \leq b_n$ tenemos que

$$\begin{aligned}
& \mathbb{P}((X_{1:n}, X_{2:n}, \dots, X_{n:n}) \in (a_1, b_1] \times (a_2, b_2] \times \dots \times (a_n, b_n]) \\
&= \mathbb{P}(\bigcup_{\sigma \in \mathcal{S}_n} \{(X_{\sigma(1)}, X_{\sigma(2)}, \dots, X_{\sigma(n)}) \in (a_1, b_1] \times (a_2, b_2] \times \dots \times (a_n, b_n]\}) \\
&= \sum_{\sigma \in \mathcal{S}_n} \mathbb{P}((X_{\sigma(1)}, X_{\sigma(2)}, \dots, X_{\sigma(n)}) \in (a_1, b_1] \times (a_2, b_2] \times \dots \times (a_n, b_n]) \\
&= \sum_{\sigma \in \mathcal{S}_n} \mathbb{P}(X_1, X_2, \dots, X_n) \in ((a_{\sigma^{-1}(1)}, b_{\sigma^{-1}(1)}] \times (a_{\sigma^{-1}(2)}, b_{\sigma^{-1}(2)}] \times \dots \times (a_{\sigma^{-1}(n)}, b_{\sigma^{-1}(n)}]) \\
&= \sum_{\sigma \in \mathcal{S}_n} \prod_{i=1}^n (b_{\sigma^{-1}(i)} - a_{\sigma^{-1}(i)}) \\
&= n! \prod_{i=1}^n (b_i - a_i).
\end{aligned}$$

En otras palabras: si $X_i \sim U_{0,1}$ con densidad 1, tenemos que

$$f_{(X_{1:n}, \dots, X_{n:n})}(t_1, \dots, t_n) = n! \mathbf{1}\{t_1 < \dots < t_n\}(t_1, \dots, t_n).$$

Se puede ver directamente para $a_i = 0$ y $b_i = t_i$, diferenciando por todas las variables una vez $\frac{d}{dt_i}$.

2. Entonces

$$\begin{aligned}
& \mathbb{P}(X_{i:n} \leq x) \\
&= n! \int_0^1 \cdots \int_0^1 \int_0^1 \int_0^1 \cdots \int_0^1 \mathbf{1}\{t_1 < t_2 < \cdots < t_{n-1} < t_n\} \cdot \mathbf{1}_{[0,x]}(t_i) dt_1 \dots dt_{i-1} dt_i dt_{i+1} \dots dt_n \\
&= n! \int_0^1 \cdots \int_0^1 \int_0^1 \int_0^1 \cdots \int_0^1 \mathbf{1}\{t_1 < t_2 \dots t_{i-1} < t_i\} \cap \{t_i < t_{i+1} \dots t_{n-1} < t_n\} \cdot \mathbf{1}\{t_i \leq x\} dt_1 \dots dt_i \dots dt_n \\
&= n! \int_0^1 \cdots \int_0^1 \int_0^1 \int_0^1 \cdots \int_0^1 \mathbf{1}\{t_1 < t_2 \dots t_{i-1} < s\} \cdot \mathbf{1}\{s < t_{i+1} < \cdots < t_n\} \\
&\quad \cdot \mathbf{1}\{s \leq x\} dt_1 \dots dt_{i-1} ds dt_{i+1} \dots dt_n \\
&= n! \int_0^1 \left(\int_0^1 \cdots \int_0^1 \int_0^1 \cdots \int_0^1 \mathbf{1}\{t_1 < t_2 \dots t_{i-1} < s\} \cdot \mathbf{1}\{s < t_{i+1} < \cdots < t_n\} \right. \\
&\quad \left. \cdot \mathbf{1}\{s \leq x\} dt_1 \dots dt_{i-1} dt_{i+1} \dots dt_n \right) ds \\
&= n! \int_0^1 \left(\int_0^1 \cdots \int_0^1 \mathbf{1}\{t_1 < t_2 \dots t_{i-1} < s\} dt_1 \dots dt_{i-1} \right) \cdot \\
&\quad \cdot \left(\int_0^1 \cdots \int_0^1 \mathbf{1}\{s < t_{i+1} < \cdots < t_n\} dt_{i+1} \dots dt_n \right) \mathbf{1}\{s \leq x\} ds \\
&= n! \int_0^x a(i-1, s) a(n-i, 1-s) ds,
\end{aligned}$$

para

$$\begin{aligned}
a(i-1, s) &= \int_0^1 \cdots \int_0^1 \mathbf{1}\{t_1 < t_2 < \cdots < t_{i-1} < s\} dt_1 \dots dt_{i-1} \\
&= \int_0^s \cdots \int_0^s \mathbf{1}\{t_1 < t_2 < \cdots < t_{i-1}\} dt_1 \dots dt_{i-1} \\
&= \frac{s^{i-1}}{(i-1)!}.
\end{aligned}$$

y

$$\begin{aligned}
& \int_0^1 \cdots \int_0^1 \mathbf{1}\{s < t_{i+1} < \cdots < t_n\} dt_{i+1} \dots dt_n \\
&= \int_s^1 \cdots \int_s^1 \mathbf{1}\{t_{i+1} < \cdots < t_n\} dt_{i+1} \dots dt_n \\
&= \int_0^{1-s} \cdots \int_0^{1-s} \mathbf{1}\{t_{i+1} < \cdots < t_n\} dt_{i+1} \dots dt_n = \frac{(1-s)^{n-i}}{(n-i)!} = a(n-i, 1-s).
\end{aligned}$$

Por tanto

$$\begin{aligned}
\mathbb{P}(X_{i:n} \leq x) &= n! \int_0^x \frac{s^{i-1}}{(i-1)!} \frac{(1-s)^{n-i}}{(n-i)!} ds \\
&= \frac{n!}{(i-1)!(n-i)!} \int_0^x s^{i-1} (1-s)^{n-i} ds \\
&= \frac{n!}{(i-1)!(n-i)!} \int_0^x s^{i-1} (1-s)^{(n-i+1)-1} ds
\end{aligned}$$

Entonces

$$X_{i:n} \sim \text{BETA}(i, n-i+1).$$

□

Lemma 2.3 (Propiedades de distribución de BETA). *Sea $X \sim \text{BETA}(\alpha, \beta)$*

$$1. \mathbb{E}[X] = \frac{\alpha}{\alpha+\beta}$$

$$2. \mathbb{V}(X) = \frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)}$$

Proof.

$$\begin{aligned}
\mathbb{E}[X] &= \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} \int_0^1 x x^{\alpha-1} (1-x)^{\beta-1} dx \\
&= \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} \int_0^1 x^\alpha (1-x)^{\beta-1} dx \\
&= \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} \frac{\Gamma(\alpha+1)\Gamma(\beta)}{\Gamma(\alpha+1+\beta)} \\
&= \frac{\Gamma(\alpha+1)}{\Gamma(\alpha)} \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha+\beta+1)} = \frac{\alpha}{\alpha+\beta}
\end{aligned}$$

y

$$\begin{aligned}
\mathbb{V}(X) &= \mathbb{E}[X^2] - \mathbb{E}[X]^2 \\
&= \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \frac{\Gamma(\alpha + 2)\Gamma(\beta)}{\Gamma(\alpha + \beta + 2)} - \left(\frac{\alpha}{\alpha + \beta}\right)^2 \\
&= \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha + \beta + 2)} \frac{\Gamma(\alpha + 2)}{\Gamma(\alpha)} - \left(\frac{\alpha}{\alpha + \beta}\right)^2 \\
&= \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha + \beta + 2)} \frac{\Gamma(\alpha + 2)}{\Gamma(\alpha)} - \left(\frac{\alpha}{\alpha + \beta}\right)^2 \\
&= \frac{(\alpha + 1)\alpha}{(\alpha + \beta + 1)(\alpha + \beta)} - \left(\frac{\alpha}{\alpha + \beta}\right)^2 \\
&= \frac{\alpha}{\alpha + \beta} \left(\frac{\alpha + 1}{(\alpha + \beta + 1)} - \left(\frac{\alpha}{\alpha + \beta}\right) \right) \\
&= \frac{\alpha}{\alpha + \beta} \left(\frac{(\alpha + 1)(\alpha + \beta) - \alpha(\alpha + \beta + 1)}{(\alpha + \beta + 1)(\alpha + \beta)} \right) \\
&= \frac{\alpha}{\alpha + \beta} \left(\frac{\alpha(\alpha + \beta) + (\alpha + \beta) - \alpha(\alpha + \beta) - \alpha}{(\alpha + \beta + 1)(\alpha + \beta)} \right) \\
&= \frac{\alpha\beta}{(\alpha + \beta + 1)(\alpha + \beta)^2}
\end{aligned}$$

□

2.1.2 La extensión para distribuciones absolutamente continuas

Ejemplo 2.4. • (X_1, \dots, X_n) i.i.d. con X_i con densidad f y función de distribución F

- Entonces para $U_i \sim \mathcal{U}_{[0,1]}$ y $\perp (U_1, \dots, U_n)$ tenemos que

$$X_i \sim F^{-1}(U_i)$$

- ¿Por qué?

$$\mathbb{P}(F^{-1}(U_i) \leq x) = \mathbb{P}(U_i \leq F(x)) = \int_0^{F(x)} dt = F(x).$$

y la independencia se hereda (¡verificar eso!). Ya sabemos que

$$U_{i:n} \sim \text{BETA}(i, n - i + 1)$$

Además F y F^{-1} son no decrecientes tal que

$$X_{i:n} = F^{-1}(U_{i:n}).$$

Por tanto

$$\mathbb{P}(X_{i:n} \leq x) = \mathbb{P}(F^{-1}(U_{i:n}) \leq x) = \mathbb{P}(U_{i:n} \leq F(x)).$$

Ahora para obtener la densidad derivamos

$$\begin{aligned} f_{X_{i:n}}(x) &= \frac{d}{dx} \mathbb{P}(X_{i:n} \leq x) \\ &= \frac{d}{dx} \mathbb{P}(U_{i:n} \leq F(x)) \\ &= \frac{d}{dx} \frac{n!}{(i-1)!(n-i)!} \int_0^{F(x)} t^{i-1} (1-t)^{n-i} dt \\ &= \frac{n!}{(i-1)!(n-i)!} (F(x))^{i-1} (1-F(x))^{n-i} f(x). \end{aligned}$$

$$\boxed{f_{X_{i:n}}(x) = \frac{n!}{(i-1)!(n-i)!} (F(x))^{i-1} (1-F(x))^{n-i} f(x)}$$

2.2 Un teorema límite para los valores extremales (Fisher-Tippett-Gnedenko)

2.2.1 Preliminares

- Por la subsucesión precedente sabemos que para un número $n \in \mathbb{N}$ fijo siempre podemos calcular la distribución en conjunto del vector $(X_{0:n}, \dots, X_{n:n})$ y también las distribuciones marginales $X_{i:n}$. Sin embargo, muchas veces (p.e. en un seguros) es importante saber cómo se comporta $X_{n:n}$ en términos de n en para X_i con una distribución genérica.

Definition 2.3. Definimos para $(X_i)_{i \in \mathbb{N}}$ i.i.d. with values in \mathbb{R}

$$M_n := X_{n:n} = \max\{X_1, \dots, X_n\}$$

el máximo para cada valor $n \in \mathbb{N}$.

Remark 2.5. • Todo lo que mostramos para los máximos sigue equivalente para el mínimo

$$\min\{X_1, \dots, X_n\} = -\max\{-X_1, \dots, -X_n\}.$$

- M_n tiene la función de distribución

$$\mathbb{P}(M_n \leq x) = \mathbb{P}(X_1 \leq x, \dots, X_n \leq x) = \mathbb{P}\left(\bigcap_{i=1}^n \{X_i \leq x\}\right) = \prod_{i=1}^n \mathbb{P}(X_i \leq x) = F^n(x).$$

Remark 2.6. • Sea $x_F := \sup\{x \in \mathbb{R} \mid F(x) < 1\}$ el “punto final de la derecha del soporte de F ” finito $x_F < \infty$. Por tanto para toda $x < x_F$

$$\mathbb{P}(M_n \leq x) = F^n(x) \rightarrow 0, \quad n \rightarrow \infty.$$

y para toda $x \geq x_F$

$$\mathbb{P}(M_n \leq x) = F^n(x) = 1, \quad \text{for all } n \in \mathbb{N}.$$

- Por tanto

$$\mathbb{P}(|M_n - x_F| \geq \varepsilon) = \mathbb{P}(M_n \leq x_F - \varepsilon) + \mathbb{P}(M_n \geq x_F + \varepsilon) = F^n(x_F - \varepsilon) + 0 \rightarrow 0, \quad n \rightarrow \infty$$

es decir $M_n \rightarrow x_F$ en probabilidad.

- Además la sucesión

$$n \mapsto M_n(\omega)$$

es no decreciente por construcción.

1. Por tanto: $x_F < \infty$ implica que $M_n \rightarrow x_F$, $n \rightarrow \infty$, \mathbb{P} -c.s.

En otras palabras: Si tenemos un valor máximo de alcanzar y una infinidad de intentos independientes, no sorprende que nos acercamos a este valor arbitrariamente cercano.

La pregunta aquí es: ¿Con cuál velocidad converge $M_n \rightarrow x_F$?

2. Si $x_F = \infty$, entonces $F(x) < 1$ para toda $x \in \mathbb{R}$ tenemos que $F^n(x) \rightarrow 0$. Por tanto, $M_n \rightarrow \infty$ casi seguro.

La pregunta aquí es: ¿Con cuál velocidad diverge $M_n \rightarrow \infty$?

2.2.2 Criterios para convergencia renormalizada

- Lo que es más interesante son las preguntas de estilo siguiente: “Cómo se comporta M_n en terminos de n ?” Con el mismo razonamiento empezamos buscando sucesiones $(c_n)_{n \in \mathbb{N}}$, $c_n > 0$ y $(d_n)_{n \in \mathbb{N}}$ en \mathbb{R}

$$\frac{M_n - d_n}{c_n} \rightarrow H$$

en distribución para H desconocido, es decir:

$$M_n \approx_d c_n \cdot H + d_n, \quad n \text{ valores grandes}$$

para un valor H aleatorio.

- Cuidado: En comparacion con el CLT NO conocemos candidatos para H .
- El teorema de Fisher-Tippet-Gnedenko nos enseñará que según las características de la distribución de X_1 obtendremos diferentes H .
- Es decir, buscamos las distribuciones límites de H y los coeficientes c_n y d_n a la vez.

Criterios de convergencia:

- Para $u_n = c_n x + d_n$

$$\mathbb{P}\left(\frac{M_n - d_n}{c_n} \leq x\right) = \mathbb{P}(M_n \leq u_n)$$

- “¿Cuáles condiciones de F asegura que $\mathbb{P}(M_n \leq u_n)$ converge para una sucesion u_n ?”
Notemos que

$$\mathbb{P}(M_n \leq u_n) = \left(F_X(u_n)\right)^n$$

Para n grande hay un juego entre las dos apariencias de n : para cualquier valor $f \in (0, 1)$ tenemos que $f^n \rightarrow 0$ y $1^n = 1$, mientras para cada $u_n \rightarrow \infty$ tenemos que $F_X(u_n) \rightarrow 1$.

La siguiente aproximación ayuda a relacionar la convergencia con el comportamiento de la función de la cola \bar{F} .

Lemma 2.7 (Aproximación de Poisson). Dado X con F_X y $\bar{F}_X(x) = 1 - F_X(x)$, $x \in \mathbb{R}$, y

- $\tau \in [0, \infty]$
- $(u_n)_{n \in \mathbb{N}}$ una sucesión no decreciente.

Entonces son equivalentes:

1. $\lim_{n \rightarrow \infty} \mathbb{P}(M_n \leq u_n) = e^{-\tau}$
2. $\lim_{n \rightarrow \infty} n\bar{F}_{X_1}(u_n) \rightarrow \tau$.

Remark 2.8. Mientras el primer límite es una condición para M_n (complicado), la segunda lo relaciona con el decrecimiento de la función de distribución de X .

Este resultado debe leerse que solo existen probabilidades propiamente hablando, es decir, si el límite en (1) es un valor $0 < e^{-\tau} < \infty$ (inclusiones estrictas). Ni siquiera estamos hablando de los valores de $e^{-\tau}$ para identificar alguna distribución en concreto, meramente la convergencia a una “masa” no trivial.

Proof. Primero el caso $\tau < \infty$:

- (2) \Rightarrow (1): Asumimos (2). Entonces

$$n\bar{F}_X(u_n) - \tau = n(\bar{F}_X(u_n) - \frac{\tau}{n}) \xrightarrow{n \rightarrow \infty} 0.$$

That is $\bar{F}_X(u_n) - \frac{\tau}{n} = o(\frac{1}{n})_{n \rightarrow \infty}$. Calculemos

$$\begin{aligned} \lim_{n \rightarrow \infty} \mathbb{P}(M_n \leq u_n) &= \lim_{n \rightarrow \infty} F(u_n)^n = \lim_{n \rightarrow \infty} (1 - \bar{F}(u_n))^n \\ &= \lim_{n \rightarrow \infty} \left(1 - \left(\frac{\tau}{n} + (F_X(u_n) - \frac{\tau}{n})\right)\right)^n = \lim_{n \rightarrow \infty} \left(1 - \frac{\tau}{n} + o(\frac{1}{n})_{n \rightarrow \infty}\right)^n \\ &= \lim_{n \rightarrow \infty} \left(1 - \frac{\tau}{n}\right)^n \xrightarrow{(2)} e^{-\tau}. \end{aligned}$$

- (1) \Rightarrow (2): Primero, notemos que (1) implica que $\bar{F}(u_n) \rightarrow 0$, $n \rightarrow \infty$.
 - En el caso contrario hubiera una subsucesión u_{n_k} con $\liminf_{k \rightarrow \infty} \bar{F}(u_{n_k}) > 0$.
 - Por tanto $\mathbb{P}(M_{n_k} \leq u_{n_k}) = (1 - \bar{F}(u_{n_k}))^{n_k} \rightarrow 0$ lo que contradice (1).

Segundo, tomando logaritmos en (1) solo tenemos que mostrar que

$$\lim_{n \rightarrow \infty} \ln(\mathbb{P}(M_n \leq u_n)) = -\tau.$$

Con la fórmula exacta de F_{M_n} podemos calcular que

$$\ln(\mathbb{P}(M_n \leq u_n)) = \ln((1 - \bar{F}_n(u_n))^n) = n \ln(1 - \bar{F}_n(u_n))$$

por tanto

$$-n \ln(1 - \bar{F}_n(u_n)) \longrightarrow \tau, \quad n \rightarrow \infty.$$

Por la fórmula de Taylor sabemos que

$$-\ln(1-x) = x + o(x)_{x \rightarrow 0+}.$$

Como ya mostramos que $\bar{F}_n(u_n) \rightarrow 0$ y la fórmula precedente obtenemos

$$\tau = \lim_{n \rightarrow \infty} -n \ln(1 - \bar{F}_n(u_n)) = \lim_{n \rightarrow \infty} n \cdot \bar{F}(u_n).$$

que es el enunciado (2).

Caso $\tau = \infty$: Ejercicio. □

Remark 2.4. • En el nivel probabilístico se se basa en el teorema límite de Poisson:

Teorema límite de Poisson:

Sea X_n una sucesión de variables aleatorias con B_{n,p_n} y $p_n \rightarrow 0$. Entonces

$$\lim_{n \rightarrow \infty} n \cdot p_n \rightarrow \lambda$$

es equivalente a

$$\mathbb{P}(X_n = k) \longrightarrow \frac{\lambda^k}{k!} e^{-\lambda}, \quad k \in \mathbb{N}_0.$$

En otras palabras

$$\mathcal{B}_{n,p_n} \xrightarrow{d} \text{Poi}(\lambda)$$

Demostración: “ \Rightarrow ”

$$\begin{aligned} \mathbb{P}(X_n = k) &= \binom{n}{k} p_n^k (1 - p_n)^{n-k} = \frac{n!}{(n-k)!} p_n^k \frac{1}{k!} (1 - p_n)^n \\ &= \frac{n!}{(n-k)!} \frac{1}{n^k} (n \cdot p_n)^k \frac{1}{k!} \left(1 - \frac{np_n}{n}\right)^n \\ &= \underbrace{\frac{n(n-1)(n-2) \dots (n-k+1)}{n^k}}_{\rightarrow 1} \underbrace{(n \cdot p_n)^k}_{\rightarrow \lambda^k} \frac{1}{k!} \underbrace{\left(1 - \frac{np_n}{n}\right)^n}_{\rightarrow e^{-\lambda}} \end{aligned}$$

“ \Leftarrow ” (muestrela) □

Detrás de la demostración es el teorema límite de Poisson. If $\tau < \infty$ we define

$$S_n := \sum_{i=1}^n \mathbf{1}\{X_i > u_n\}$$

Ahora, $S_n \sim \mathcal{B}_{n,\bar{F}(u_n)}$ and $S_n \rightarrow \mathcal{P}_\tau$ if and only if

$$\mathbb{E}[S_n] = n\bar{F}(u_n) \rightarrow \tau.$$

- Then $\mathbb{P}(M_n \leq u_n) = \mathbb{P}(S_n = 0) \longrightarrow e^{-\tau} \frac{\tau^0}{0!}$. Por eso se llama “Aproximación de Poisson”.

Remark 2.5. ¿Qué tan universal es esta escogencia? \rightarrow bastante.

- Si existe una τ y una sucesión $(u_n(\tau))_{n \in \mathbb{N}}$ tal que

$$n\bar{F}(u_n(\tau)) \xrightarrow{n \rightarrow \infty} \tau$$

entonces encontramos una subsucesión $(u_n(\tau'))_{n \in \mathbb{N}}$ para cualquier $\tau' > 0$.

- Por ejemplo si tenemos $u_n(1)$

$$n\bar{F}(u_n(1)) \xrightarrow{n \rightarrow \infty} 1$$

entonces para

$$v_n(\tau) := u_{\lceil \frac{n}{\tau} \rceil}(1)$$

tenemos (reemplazando n por $\lceil \frac{n}{\tau} \rceil$) que

$$\lceil \frac{n}{\tau} \rceil \cdot \bar{F}(v_n(\tau)) \xrightarrow{n \rightarrow \infty} 1.$$

Ahora

$$\frac{\lceil \frac{n}{\tau} \rceil}{n} = \frac{\frac{n}{\tau} + (\lceil \frac{n}{\tau} \rceil - \frac{n}{\tau})}{n} = \frac{1}{\tau} + \frac{\lceil \frac{n}{\tau} \rceil - \frac{n}{\tau}}{n} \rightarrow \frac{1}{\tau}.$$

Por tanto

$$n \cdot \bar{F}(v_n(\tau)) = \frac{n}{\lceil \frac{n}{\tau} \rceil} \lceil \frac{n}{\tau} \rceil \cdot \bar{F}(v_n(\tau)) \xrightarrow{n \rightarrow \infty} \tau.$$

Ahora miramos cuando podemos decir algo sobre la convergencia $M_n \rightarrow x_F < \infty$, es decir si tenemos un maximo posible finito de la distribución. Primero excluyamos distribuciones finitas que se “rompen” al final.

Lemma 2.9 (Criterio de degeneración).

Sea

- $x_F := \inf\{t > 0 \mid F_X(t) = 1\} < \infty$, *maximo accesible finito.*
- $\bar{F}(x_F-) = F(x_F) - F(x_F-) > 0$, *es decir, hay un “salto discreto” de \bar{F} en este punto final x_F .*

Entonces para cada sucesión no decreciente $(u_n)_n$ tal que

$$\lim_{n \rightarrow \infty} \mathbb{P}(M_n \leq u_n) = \rho,$$

tenemos que $\rho \in \{0, 1\}$.

Este resultado excluye límites no degenerados en el lema 2.7 (1)).

Proof. • Como $\rho \in [0, 1]$ podemos reescribirlo como $\rho = \exp(-\tau)$ para alguna $\tau \in [0, \infty]$.

- Por la aproximación de Poisson tenemos que $\mathbb{P}(M_n \leq u_n) \rightarrow \rho$ es equivalente a

$$n\bar{F}(u_n) \rightarrow \tau.$$

- Ahora cuales (u_n) podemos considerar?
 1. $u_n < x_F$ una infinidad de n
 2. $u_n < x_F$ para un número finito de n
- Si $u_n < x_F$ para una infinidad de n entonces

$$\bar{F}(u_n) \geq \bar{F}(x_F-) > 0 \text{ para estas } n.$$

Es decir

$$\liminf_{n \rightarrow \infty} \bar{F}(u_n) > 0$$

lo que con $n\bar{F}(u_n) \rightarrow \tau$ implica que $\tau = \infty$ y $\rho = 0$.

- Si $u_n < x_F$ para solo un numero finito, existe un número N suficientemente grande a partir del cual $u_n \geq x_F$, $n \geq N$ y por tanto entonces $n\bar{F}(u_n) = 0$ y por tanto $\tau = 0$ y $\rho = 1$.

□

Remark 2.10. Si para $x_F < \infty$ tenemos un “salto” a cero, entonces para toda u_n es decir para cualquier renormalización c_n, d_n tenemos que

$$\mathbb{P}\left(\frac{M_n - d_n}{c_n} \leq x\right) \rightarrow \mathbf{1}(-\infty, x_F](x).$$

es decir

$$\frac{M_n - d_n}{c_n} \rightarrow \delta_{x_F},$$

y ninguna “distribución límite no trivial”.

En el lema anterior vimos (para el caso de $x_F < \infty$) que tener una discontinuidad de \bar{F} en x_F excluye teoremas límites no triviales. El siguiente teorema en combinación con la aproximación de Poisson (Lema 2.7) nos da que la continuidad de \bar{F} en x_F es equivalente a tener una distribución límite no trivial.

Theorem 2.6 (Resultado negativo).

Dado X con F_X y $\bar{F}_X(x) = 1 - F_X(x)$, $x \in \mathbb{R}$ y

- $x_F \leq \infty$,
- $\tau \in (0, \infty)$.

Entonces son equivalentes

1. Existe una sucesión $(u_n)_n$ tal que

$$n\bar{F}(u_n) \xrightarrow{n \rightarrow \infty} \tau$$

2.

$$\lim_{x \rightarrow x_F -} \frac{\bar{F}(x)}{\bar{F}(x-)} = 1.$$

Remark 2.11. • El juego se determina por la continuidad de F_X (y de \bar{F}_X) en x_F .

- Para distribuciones continuas F_X esto siempre se satisface, sea $x_F < \infty$ o $x_F = \infty$.
- Para distribuciones discretas con valores en \mathbb{N} y $x_F = \infty$ podemos calcular

$$\begin{aligned} \frac{\bar{F}(n)}{\bar{F}(n-1)} &= \frac{\sum_{i=n}^{\infty} f(i)}{\sum_{i=n-1}^{\infty} f(i)} \\ &= \frac{\sum_{i=n-1}^{\infty} f(i)}{\sum_{i=n-1}^{\infty} f(i)} - \frac{f(n-1)}{\sum_{i=n-1}^{\infty} f(i)} \\ &= 1 - \frac{f(n-1)}{\bar{F}(n-1)}. \end{aligned}$$

Entonces el límite en 2. es equivalente a que

$$\lim_{n \rightarrow \infty} \frac{f(n)}{\bar{F}(n)} = 0.$$

- Este criterio precedente excluye muchas distribuciones discretas con soporte infinito. En particular los casos donde la densidad es proporcional a su antiderivada, como en los casos “geométricos”.

In the absolutely continuous case this is very different. “Almost all” absolutely continuous distributions have extreme value distributions.

Ejemplo 2.12 (Geométrica: excluida). • $\mathbb{P}(X = k) = p(1-p)^{k-1}$, $k \in \mathbb{N}, p \in (0, 1)$

- Para $k \in \mathbb{N}$

$$\frac{\bar{F}(k)}{\bar{F}(k-1)} = 1 - \frac{(1-p)^{k-1}}{\sum_{r=k}^{\infty} (1-p)^{r-1}} = 1 - p < 1.$$

- Por tanto cada límite de (u_n) satisface

$$\mathbb{P}(M_n \leq u_n) \longrightarrow \rho \in \{0, 1\}.$$

- La distribución binomial negativa (¿de dónde viene?)

$$\mathbb{P}(X = k) = \binom{v+k-1}{k-1} p^v (1-p)^{k-1}, k \in \mathbb{N}_0, 0 < k < 1, v > 0.$$

tambien satisface que

$$\frac{\bar{F}(k)}{\bar{F}(k-1)} \leq (1-p) < 1.$$

- Paila.

Ejemplo 2.13 (Poisson: pa fuera). • $\mathbb{P}(X = k) = e^{-\lambda} \frac{\lambda^k}{k!}, \quad k \in \mathbb{N}_0$

- Calculemos

$$\begin{aligned} \frac{\bar{F}(k)}{\bar{F}(k-1)} &= 1 - \frac{F(k) - F(k-1)}{\bar{F}(k-1)} \\ &= 1 - \frac{\frac{\lambda^k}{k!}}{\sum_{r=k}^{\infty} \frac{\lambda^r}{r!}} = 1 - \frac{\frac{\lambda^k}{k!}}{\frac{\lambda^k}{k!} + \sum_{r=k+1}^{\infty} \frac{\lambda^r}{r!}} \\ &= 1 - \frac{1}{\left(1 + \sum_{r=k+1}^{\infty} \frac{k!}{r!} \lambda^{r-k}\right)} \\ &= 1 - \frac{1}{\left(1 + \sum_{s=1}^{\infty} \frac{\lambda^s}{(k+1)(k+2)\dots(k+s)}\right)} \end{aligned}$$

- Esta última series se estima como

$$\sum_{s=1}^{\infty} \frac{\lambda^s}{(k+1)(k+2)\dots(k+s)} \leq \sum_{s=1}^{\infty} \left(\frac{\lambda}{k}\right)^s = \frac{\frac{\lambda}{k}}{1 - \frac{\lambda}{k}}, \quad k > \lambda.$$

Para $k \rightarrow \infty$ tenemos

$$\begin{aligned} \lim_{k \rightarrow \infty} \frac{\bar{F}(k)}{\bar{F}(k-1)} &= 1 - \lim_{k \rightarrow \infty} \frac{1}{\left(1 + \sum_{s=1}^{\infty} \frac{\lambda^s}{(k+1)(k+2)\dots(k+s)}\right)} \\ &\leq 1 - \lim_{k \rightarrow \infty} \frac{1}{\left(1 + \frac{\frac{\lambda}{k}}{1 - \frac{\lambda}{k}}\right)} = 1 - \frac{1}{1+0} = 0. \end{aligned}$$

- Por tanto cada límite de una sucesión $(u_n)_n$ posible satisface

$$\mathbb{P}(M_n \leq u_n) \longrightarrow \rho \in \{0, 1\}.$$

Ejemplo 2.14 (Colas pesadas: no excluidas).

- Consideramos $X \sim \sum_{i=1}^{\infty} \left(\frac{1}{i} - \frac{1}{i+1} \right) \delta_i$.
- Ahora la densidad discreta es

$$f(n) = \frac{1}{n} - \frac{1}{n+1} = \frac{1}{n(n+1)}.$$

- mientras

$$\bar{F}(n) = \sum_{i=n}^{\infty} f(i) = \sum_{i=n}^{\infty} \frac{1}{i(i+1)} \geq \sum_{i=n}^{\infty} \frac{1}{(i+1)^2} = \sum_{i=n-1}^{\infty} \frac{1}{i^2} \geq \int_n^{\infty} \frac{1}{x^2} dx = \frac{1}{n}$$

- Consequently,

$$\frac{f(n)}{\bar{F}(n)} = \frac{1}{n(n+1)} n = \frac{1}{n+1} \rightarrow 0.$$

2.2.3 Los ejemplos prototípicos y la formulación del teorema principal

Finalmente queremos conocer posibles distribuciones límites a las cuales $(M_n - d_n)/c_n \rightarrow ?$ puedan converger.

Example 2.7 (Exponentials: growing maximum, Gumbel, Type 1).

- $(X_i)_i$ i.i.d. con $X_1 \sim \text{EXP}(\alpha)$, $\alpha > 0$
- Ya que $\bar{F}(x) = e^{-\alpha x} \in (0, 1)$ para toda $x > 0$ tenemos que

$$\mathbb{P}(M_n \leq x) = (1 - \bar{F}(x))^n \rightarrow 0.$$

Adivinando que M_n crece como función n de manera logarítmica.

- Sustrayendo el logaritmo podría estabilizar. Consideramos $M_n - \frac{\ln(n)}{\alpha}$. Notemos que la x siguiente puede estar en toda \mathbb{R} porque se pueden producir valores negativos por recentrar. Es decir, para $x \in \mathbb{R}$ tenemos

$$\begin{aligned} \mathbb{P}(M_n - \frac{\ln(n)}{\alpha} \leq x) &= \mathbb{P}(M_n \leq x + \frac{\ln(n)}{\alpha}) \\ &= (1 - \bar{F}(x + \frac{\ln(n)}{\alpha}))^n \\ &= (1 - \exp(-\alpha(x + \frac{\ln(n)}{\alpha})))^n \\ &= (1 - \exp(-(\alpha x + \ln(n))))^n = (1 - \frac{e^{-\alpha x}}{n})^n \rightarrow e^{-e^{-\alpha x}}. \end{aligned}$$

Wow, esto es algo inesperado, y no es una de las distribuciones típicas. La función de distribución que obtenemos es

$$G(x) = e^{-e^{-\alpha x}}$$

- Es una función de distribución? Es continua,

$$\lim_{x \rightarrow \infty} e^{-e^{-\alpha x}} = e^{-\lim_{x \rightarrow \infty} e^{-\alpha x}} = 1.$$

y

$$\lim_{x \rightarrow -\infty} e^{-e^{-\alpha x}} = 0.$$

Es una distribución Gumbel.

- En este caso $c_n = 1$ y $d_n = \frac{\ln(n)}{\alpha}$.

Example 2.8 (Pareto: growing maxima, Fréchet, Type 2).

- Para $\alpha > 0$ sea $\bar{F}(x) := \begin{cases} 1 & x \leq 1 \\ \frac{1}{x^\alpha} & x > 1 \end{cases}$.

- Entonces para $x > 1$ tenemos que $\bar{F}(x) \in (0, 1)$ y

$$\mathbb{P}(M_n \leq x) \rightarrow 0, n \rightarrow \infty \text{ para } x > 1.$$

- Entonces M_n crece en n . Como es de colas pesadas en vez recentrar podría parecer natural renormalizar por una potencia de n .
- Consideramos $M_n/n^{\frac{1}{\alpha}}$. Por la renormalización puede haber valores en todos positivos por tanto asumimos $x > 0$

$$\mathbb{P}\left(\frac{M_n}{n^{\frac{1}{\alpha}}} \leq x\right) = \mathbb{P}(M_n \leq n^{\frac{1}{\alpha}}x) = \left(1 - \frac{1}{x^\alpha n}\right)^n \rightarrow e^{-\frac{1}{x^\alpha}}.$$

Wow, otra función de distribución no estándar! Es continua con

$$\lim_{x \rightarrow \infty} e^{-\frac{1}{x^\alpha}} = 1$$

y

$$\lim_{x \rightarrow 0} e^{-\frac{1}{x^\alpha}} = 0$$

Se llama la distribución de Fréchet.

- en este caso $d_n = 0$, $c_n = n^{\frac{1}{\alpha}}$.

Example 2.9 (Finite range, approximation to the maximum, Weibull, Type 3).

$$\bullet \quad \bar{F}(x) = \begin{cases} 1 & x \leq 0 \\ (1-x)^\alpha & x \in [0, 1] \\ 0 & x > 1 \end{cases}$$

- $x_F = 1$ por tanto $M_n \rightarrow 1$ c.s. ¿la pregunta es: qué tan rápido converge? Si inflamos esta convergencia

$$n^{\frac{1}{\alpha}}(M_n - 1)$$

y converge podemos ver la tasa de convergencia precisa:

Para $-n^{\frac{1}{\alpha}} \leq x \leq 0$ tenemos

$$\begin{aligned} \mathbb{P}(n^{\frac{1}{\alpha}}(M_n - 1) \leq x) &= \mathbb{P}(M_n \leq \frac{x}{n^{\frac{1}{\alpha}}} + 1) \\ &= \left(1 - \left(1 - \left(\frac{-x}{n^{\frac{1}{\alpha}}} + 1\right)\right)^\alpha\right)^n \\ &= \left(1 - \frac{(-x)^\alpha}{n}\right)^n \rightarrow e^{-(-x)^\alpha} \end{aligned}$$

- Por tanto

$$\mathbb{P}(n^{\frac{1}{\alpha}}(M_n - 1) \leq x) \rightarrow \begin{cases} e^{-(-x)^\alpha}, & x \leq 0 \\ 1, & x > 0 \end{cases}$$

Otra vez, es una distribución no estándar, y se llama la distribución de Weibull.

- En este caso: $c_n = \frac{1}{n^{\frac{1}{\alpha}}}$ y $d_n = 1$.

A word about the limit distributions:

1. La distribución de Gumbel:

- Para los parametros $m \in \mathbb{R}$, $\beta > 0$ la distribución de **Gumbel** $\Lambda_{m,\beta}$ tiene la función de distribución siguiente

$$F(x) = \exp\left(-e^{-\frac{(x-m)}{\beta}}\right), \quad x \in \mathbb{R}$$

- La densidad es

$$f(x) = \frac{1}{\beta} \exp\left(\left(-\frac{(x-m)}{\beta}\right) \cdot \left(-e^{-\frac{(x-m)}{\beta}}\right)\right) = \frac{1}{\beta} \frac{e^{-\frac{(x-m)}{\beta}}}{\exp\left(e^{-\frac{(x-m)}{\beta}}\right)}$$

- Esencialmente una distribución exponencial “adornada” con algún prefactor entre $e^0 = 1$ y e^1 pero con valores negativos que son muy pequeños. Se verifica por l'Hopital se muestra la convergencia para valores negativos. Es una Entonces tiene todos los momentos.
- Es una distribución asimétrica, no centrada, con máximo de la densidad en m .
- Momentos: en general complicado, integración por partes en el caso del valor esperado permite calcular

$$\mathbb{E}[X] = \int_{-\infty}^{\infty} x \frac{1}{\beta} e^{-\frac{(x-m)}{\beta}} \cdot \left(-e^{-\frac{(x-m)}{\beta}}\right) dx = m + \gamma\beta$$

para

$$\gamma = \lim_{n \rightarrow \infty} \ln(n) - \sum_{i=1}^n \frac{1}{i} \approx 0.57721... \quad \text{la constante de Euler-Mascheroni}$$

y

$$\mathbb{V}[X] = \frac{\pi^2}{6} \beta^2.$$


- Gumbel estándar $\Lambda = \Lambda_{0,1}$, $m = 0$, $\beta = 1$

$$F(x) = e^{-e^{-x}}, \quad x \in \mathbb{R}$$

- con densidad

$$f(x) = \frac{1}{\beta} e^{(-x)(-e^{-x})} = \frac{1}{\beta} \frac{e^{-x}}{\exp(e^{-x})}.$$

WolframAlpha plot: Standard Gumbel density.



2. Distribución de **Fréchet** $\Phi_{\alpha,\beta,m}$ con parametros $\alpha > 0$, $\beta > 0$ y $m \in \mathbb{R}$

$$F(x) = \begin{cases} e^{-(\frac{x-m}{\beta})^{-\alpha}} & x > 0 \\ 0 & x \leq 0 \end{cases}$$

- con densidad

$$f(x) = \begin{cases} \frac{\alpha}{\beta} \frac{e^{-(\frac{x-m}{\beta})^{-\alpha}}}{(\frac{x-m}{\beta})^{\alpha+1}} & x > 0 \\ 0 & x \leq 0 \end{cases}$$

- Fréchet estándar $\Phi_{\alpha} = \Phi_{\alpha,1,0}$ para $\alpha > 0$

$$F(x) = \begin{cases} e^{-x^{-\alpha}} & x > 0 \\ 0 & x \leq 0 \end{cases}$$

con densidad

$$f(x) = \begin{cases} \alpha \frac{e^{-x^{-\alpha}}}{x^{\alpha+1}} & x > 0 \\ 0 & x \leq 0 \end{cases}$$

sólo momentos para $\alpha < k$. Es una distribución con colas pesadas, con soporte solo positivo.

- Para $k < \alpha$ tenemos los momentos

$$\begin{aligned}
 \mathbb{E}[X^k] &= \int_0^{\infty} x^k f_{\alpha}(x) dx \\
 &= \int_0^{\infty} x^k \alpha \frac{e^{-x^{-\alpha}}}{x^{\alpha+1}} dx \\
 &= \int_0^{\infty} t^{-\frac{k}{\alpha}} e^{-t} dt \\
 &= \int_0^{\infty} t^{(-\frac{k}{\alpha}+1)-1} e^{-t} dt \\
 &= \Gamma(1 - \frac{k}{\alpha})
 \end{aligned}$$

por la sustitución $t = x^{-\alpha}$ con los detalles $x = t^{-\frac{1}{\alpha}}$, $\frac{dt}{dx} = -\alpha x^{-\alpha-1}$, $x = 0$ implica $t = \infty$ y $x = \infty$ implica $t = 0$.


- La varianz se calcula por

$$\mathbb{V}(X) = \mathbb{E}[X^2] - \mathbb{E}[X]^2$$

por la formula anterior: Para $\alpha > 2$ tenemos que

$$\mathbb{V}(X) = \Gamma(1 - \frac{2}{\alpha}) - \Gamma^2(1 - \frac{1}{\alpha}).$$

WolframAlpha plot: Frechet density $\alpha = 1$.



3. La distribución de Weibull $\tilde{\Psi}_{\alpha,\lambda}$ con parametros $\alpha, \lambda > 0$

- tiene la función de distribución

$$F(x) = e^{-(\lambda x)^\alpha} \mathbf{1}\{x \geq 0\}$$

- y la densidad

$$f(x) = \alpha \lambda^\alpha x^{\alpha-1} e^{-x^\alpha} \mathbf{1}\{x \geq 0\}$$

- En el teorema aparece la distribución de **Weibull estándar** Ψ_α **reflejada**, es decir, $X \sim \Psi_\alpha$ significa que $-X \sim \tilde{\Psi}_{\alpha,1}$ para $\alpha > 0$.

$$F(x) = e^{-(-x)^\alpha} \mathbf{1}\{x \leq 0\} + \mathbf{1}\{x > 0\}$$

- y la densidad

$$f(x) = \alpha (-x)^{\alpha-1} e^{-(-x)^\alpha} \mathbf{1}\{x \leq 0\}$$

- Es una función de Gamma “reescalada”. La distribución tiene valores estrictamente negativos y una decaencia exponencial en la cola, y por tanto tiene todos los momentos que se pueden calcular explícitamente para Ψ_α .

$$\mathbb{E}[X] = -\Gamma(1 - \frac{1}{\alpha})$$


y

$$\mathbb{E}[X^k] = \begin{cases} -\Gamma(1 + \frac{k}{\alpha}) & k \text{ par} \\ \Gamma(1 + \frac{k}{\alpha}) & k \text{ impar} \end{cases}$$

Además

$$\mathbb{V}(X) = \Gamma(1 + \frac{2}{\alpha}) - \Gamma^2(1 + \frac{1}{\alpha})$$

WolframAlpha plot: Weibull (reflejada) con $\alpha = 2$



Theorem 2.15 (Fisher-Tippett-Gnedenko extreme value theorem).

- $(X_n)_n$ i.i.d.

Si existen constantes $c_n > 0$ y d_n y H no degenerado tal que

$$\frac{M_n - d_n}{c_n} \xrightarrow{d} H$$

entonces H pertenece a una de las distribuciones siguientes:

Gumbel

$$\Lambda(x) = \exp(-e^{-x}), x \in \mathbb{R}.$$

Fréchet $\alpha > 0$

$$\Phi_\alpha(x) = \begin{cases} 0 & x \leq 0 \\ \exp(-\frac{1}{x^\alpha}) & x > 0 \end{cases}$$

Weibull $\alpha > 0$

$$\Psi_\alpha(x) = \begin{cases} \exp(-(-x)^\alpha) & x \leq 0 \\ 1 & x > 0 \end{cases}$$